

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ



BÁO CÁO BÀI TẬP LỚN
Học phần: Học máy (Mã HP: INT3405)

PHÂN LOẠI CẢM XÚC TỪ SÓNG
NÃO EEG

Nhóm sinh viên thực hiện (Nhóm 3):

- | | |
|-----------------------|------------|
| 1. [Nguyễn Đức Long] | [24022391] |
| 2. [Phạm Thái Dương] | [24022307] |
| 3. [Nguyễn Tiến Dũng] | [24022301] |

Mục lục

Tóm tắt nội dung	3
1 Đặt vấn đề	3
2 Cơ sở dữ liệu và tiền xử lý dữ liệu	4
2.1 Giới thiệu bộ dữ liệu DEAP	4
2.2 Kỹ thuật gán nhãn (Global Median Thresholding)	5
2.3 Quy trình chuẩn bị và Tiền xử lý (Preprocessing Pipeline)	5
3 Thiết lập thực nghiệm và Đánh giá	5
3.1 Các kịch bản thực nghiệm (3×3 Matrix)	5
3.2 Kiểm soát rò rỉ dữ liệu (Data Leakage)	6
3.3 Xử lý ngoại lệ và Tiêu chí đánh giá (Metrics)	6
4 Kiến trúc các mô hình	7
4.1 Tổng quan kiến trúc hệ thống	7
4.2 Mô hình SVM	7
4.2.1 Chiến lược trích xuất đặc trưng	7
4.2.2 Kỹ thuật làm mượt LDS	8
4.2.3 Thiết kế bộ phân loại	8
4.3 Mô hình CNN 2D	10
4.3.1 Thiết kế kiến trúc	10
4.3.2 Khởi tạo trọng số	10
4.3.3 Cơ chế điều chỉnh Learning Rate thích nghi (AdaptiveLRScheduler)	11
4.4 Mô hình BiLSTM	12
4.4.1 Thiết kế kiến trúc	12
4.4.2 Thiết lập huấn luyện	12
4.4.3 Chuẩn hóa dữ liệu	13
5 Kết quả thực nghiệm và So sánh mô hình	14
5.1 Kết quả Exp 1 — Phân loại nhị phân (Subject-Dependent, 5-Fold CV)	14
5.2 Kết quả Exp 2 — Phân loại 4 lớp (Subject-Dependent, 5-Fold CV)	14
5.3 Kết quả Exp 3 — Leave-One-Subject-Out (LOSO)	14
5.4 Phân tích so sánh tổng thể	15
5.4.1 So sánh giữa các mô hình và cách thức huấn luyện mô hình	15
5.4.2 Phân tích hiện tượng Overfitting	17

6	Cải tiến mô hình	17
6.1	Cải tiến đường ống đặc trưng: PSD và Differential Entropy	17
6.2	Kiến trúc lai CNN-BiLSTM (Dual-Branch Fusion với DGCNN)	18
6.2.1	Chuẩn bị đặc trưng đầu vào	19
6.2.2	Nhánh A — DGCNN (Dynamic Graph Convolutional Neural Network)	19
6.2.3	Nhánh B — BiLSTM trên đặc trưng tần số	19
6.2.4	Lớp hợp nhất và phân loại (Fusion Head)	20
6.2.5	Hàm mục tiêu tổng hợp (Joint Loss)	20
6.2.6	Chiến lược thích nghi cá nhân (Few-Shot Calibration)	20
6.3	Mô hình EEGNet chuyên biệt	20
6.4	Fine-tuning thích nghi cá nhân (Subject-Specific Fine-tuning) dành cho EEGNet	21
6.5	Một số cải tiến khác	22
7	Hạn chế	23
8	Kết luận	24
9	Phân chia công việc	24

Tóm tắt nội dung

Nghiên cứu này tập trung giải quyết bài toán nhận diện và phân loại cảm xúc con người trên hai chiều không gian Valence và Arousal sử dụng tín hiệu điện não đồ (EEG) từ tập dữ liệu chuẩn quốc tế DEAP. Để đảm bảo tính khách quan và minh bạch trong thực nghiệm, nhóm nghiên cứu thiết lập một quy trình đánh giá nghiêm ngặt bằng việc cố định giá trị ngẫu nhiên $\text{seed} = 42$, sử dụng chung một đường ống tiền xử lý dữ liệu (*Data Pipeline*), và đồng nhất hệ thống cấu hình đánh giá.

Trong giai đoạn đầu, nhóm triển khai độc lập ba hướng tiếp cận cốt lõi: Mô hình SVM kết hợp kỹ thuật giảm chiều đặc trưng, mô hình CNN 2D trích xuất đặc trưng không gian, và mô hình BiLSTM nhằm học các phụ thuộc thời gian. Kết quả thực nghiệm chỉ ra rằng cách tiếp cận End-to-End từ biên độ sóng thô gặp hạn chế do tỷ lệ tín hiệu trên nhiễu (SNR) của EEG rất thấp, khiến các mô hình học sâu dễ rơi vào quá khớp (Overfitting).

Nhằm tối ưu hóa bài toán, nhóm đề xuất hướng đi tiếp theo: trích xuất đặc trưng miền tần số thông qua Mật độ phổ công suất (PSD) và Entropy vi phân (DE) trên các dải sóng não chuyên biệt ($\theta, \alpha, \beta, \gamma$) dùng cho mô hình mới là sự tích hợp thế mạnh không gian của CNN và thời gian của BiLSTM vào một kiến trúc lai hoàn chỉnh (CNN-BiLSTM) để đạt hiệu năng phân loại cao nhất. Bên cạnh đó là sử dụng mô hình EEGNet chuyên biệt cho mô hình sóng não

1. Đặt vấn đề

Cảm xúc đóng vai trò cốt lõi và là chất xúc tác không thể thiếu trong giao tiếp xã hội, nhận thức cũng như quá trình ra quyết định của con người. Trong kỷ nguyên tương tác Người - Máy (Human-Computer Interaction - HCI) và các hệ thống thần kinh máy tính (BCI) phát triển vượt bậc như hiện nay, việc xây dựng các hệ thống có khả năng thấu hiểu được trạng thái tâm lý người dùng là một nhu cầu cấp thiết. Để định lượng và mô hình hóa trạng thái cảm xúc, mô hình không gian hai chiều của Russell thường được áp dụng rộng rãi, bao gồm trục *Valence* (thể hiện mức độ dễ chịu từ tiêu cực đến tích cực) và trục *Arousal* (thể hiện mức độ kích động từ bình tĩnh đến phấn khích).

Trong số các nguồn tín hiệu, điện não đồ (EEG) là tín hiệu sinh lý học khách quan và trực tiếp nhất phản ánh trạng thái cảm xúc (Valence và Arousal) so với biểu cảm khuôn mặt hay giọng nói (vốn có thể bị che giấu). Do đó, phân loại cảm xúc dựa trên sóng não EEG đang khẳng định là một hướng đi mang tính khách quan, đáng tin cậy và có giá trị khoa học cao.

Mặc dù sở hữu nhiều tiềm năng vượt trội, việc xử lý và xây dựng mô hình học máy cho tín hiệu EEG phải đối mặt với ba thách thức cốt lõi:

1. **Tỷ lệ tín hiệu trên nhiễu cực thấp (Low SNR):** Tín hiệu EEG truyền qua các lớp màng não và xương sọ nên biên độ thu được vô cùng nhỏ (bậc microvolt). Chúng rất dễ bị chèn ép và làm sai lệch bởi các nguồn nhiễu sinh lý ngoại vi mạnh mẽ (nhiều chớp mắt EOG, nhiều cơ mặt EMG, nhiều nhịp tim ECG) cũng như nhiễu kỹ thuật từ môi trường.
2. **Sự khác biệt lớn giữa các cá thể (Cross-subject variability):** Do đặc tính sinh học, cấu trúc hộp sọ và cách phản ứng trước các kích thích cảm xúc của mỗi cá nhân là hoàn toàn khác biệt. Điều này khiến mô hình học máy rất dễ bị suy giảm hiệu năng khi kiểm thử trên một người dùng mới.
3. **Tính chất đa chiều phức tạp:** Tín hiệu EEG đồng thời mang đặc trưng không gian (mối tương quan giữa vị trí các điện cực trên da đầu) và đặc trưng chuỗi thời gian (sự biến đổi liên tục của biên độ sóng).

Ban đầu, nhóm nghiên cứu đã tiếp cận bài toán theo hướng End-to-End Deep Learning, đưa trực tiếp chuỗi thời gian biên độ sóng thô vào các mô hình CNN và BiLSTM độc lập. Tuy nhiên, qua quá trình chạy thực nghiệm, nhóm nhận thấy các mô hình học sâu thuần túy khi làm việc với dữ liệu sóng thô có xu hướng học thuộc lòng các thành phần nhiễu.

Từ quan sát đó, nhóm thiết kế một chiến lược nghiên cứu hai giai đoạn. Giai đoạn một xây dựng khung so sánh công bằng giữa ba mô hình đơn lẻ: SVM, CNN 2D và BiLSTM trên cùng một data pipeline. Giai đoạn hai — đóng góp cốt lõi của nhóm — áp dụng trích xuất đặc trưng miền tần số (PSD, DE) làm đầu vào cho kiến trúc lai CNN-BiLSTM và EEGNet, nhằm khắc phục hạn chế của từng mô hình đơn lẻ.

2. Cơ sở dữ liệu và tiền xử lý dữ liệu

2.1 Giới thiệu bộ dữ liệu DEAP

Bộ dữ liệu DEAP (Database for Emotion Analysis using Physiological signals) được sử dụng làm quy chuẩn cho nghiên cứu này, bao gồm dữ liệu điện tâm lý của 32 người tham gia. Tín hiệu được thu thập qua 32 kênh điện cực EEG chuẩn quốc tế. Trong quá trình thu thập, mỗi cá nhân theo dõi 40 đoạn video ca nhạc (mỗi đoạn dài 1 phút) nhằm kích thích các vùng cảm xúc khác nhau. Nhân dữ liệu được chính người tham gia tự đánh giá theo thang điểm từ 0 đến 9, tập trung vào hai chiều cốt lõi của không gian cảm xúc: Valence (Mức độ tích cực) và Arousal (Mức độ kích động).

2.2 Kỹ thuật gán nhãn (Global Median Thresholding)

Một trong những thách thức lớn nhất của bộ dữ liệu DEAP là sự phân bố nhãn không đồng đều giữa các cá thể. Do đó, thay vì áp dụng ngưỡng phân chia cố định 5.0, nhóm nghiên cứu đã cải tiến bằng cách sử dụng ngưỡng trung vị toàn cục (Global Median Thresholding). Trung vị được tính toán trên toàn bộ 32 đối tượng, cho ra ngưỡng phân lớp là 3.08 đối với Valence và 3.315 đối với Arousal. Các giá trị bằng hoặc vượt qua ngưỡng trung vị này sẽ được gán nhãn *High*, ngược lại là *Low*. Cải tiến này giúp giải quyết tình trạng mất cân bằng cục bộ, đưa tỷ lệ phân bố nhãn trong bài toán 4 lớp về trạng thái cân bằng hơn (khoảng 30% / 20% / 20% / 30%).

2.3 Quy trình chuẩn bị và Tiền xử lý (Preprocessing Pipeline)

Nhằm trích xuất tín hiệu thần kinh tinh khiết và tối ưu hóa chi phí tính toán, dữ liệu thô được đưa qua một đường ống tiền xử lý nghiêm ngặt:

- **Chắt lọc dải tần mục tiêu:** Các dải tần mang tín hiệu cảm xúc bao gồm Theta (4-8 Hz), Alpha (8-13 Hz), Beta (13-30 Hz) và Gamma (30-50 Hz) được giữ lại. Đặc biệt, dải Delta (0.5-4 Hz) bị loại bỏ hoàn toàn do dải sóng này chủ yếu xuất hiện trong trạng thái ngủ sâu và không đóng góp thông tin phân loại cảm xúc.
- **Trừ nhiễu nền (Baseline Subtraction):** Mỗi đoạn dữ liệu (trial) có tổng thời lượng 63 giây, trong đó 3 giây đầu tiên là trạng thái nghỉ ngơi tĩnh. Đầu tiên, nhóm tính giá trị biên độ trung bình của tín hiệu trong 3 giây trạng thái nghỉ. Sau đó, trừ đi giá trị trung bình này khỏi 60 giây tín hiệu kích thích để loại bỏ nhiễu nền trôi dạt. Cuối cùng, 3 giây nghỉ được loại bỏ khỏi pha huấn luyện.
- **Phân đoạn cửa sổ thời gian (Epoching):** Chuỗi tín hiệu 60 giây được cắt thành các cửa sổ nhỏ (epoch) với độ dài 1 giây (128 samples) và không có sự chồng lấp. Kỹ thuật cấp phát vùng nhớ độc lập (`.copy()`) được áp dụng trong bước này để ngăn chặn rủi ro rò rỉ hoặc trộn lẫn dữ liệu giữa các kênh điện cực.

3. Thiết lập thực nghiệm và Đánh giá

3.1 Các kịch bản thực nghiệm (3×3 Matrix)

Để đối chiếu toàn diện hiệu năng của ba mô hình (SVM, CNN 2D, và BiLSTM), hệ thống đánh giá được chia thành ba kịch bản chính:

1. **Exp 1 (Baseline 2-class, Subject-Dependent):** Trộn chung toàn bộ dữ liệu của 32 đối tượng để phân loại nhị phân độc lập trên từng chiều Valence hoặc Arousal. Quá trình huấn luyện sử dụng kiểm chéo phân tầng Stratified K-Fold với $k = 5$ nhằm đánh giá khả năng trích xuất đặc trưng chung.
2. **Exp 2 (4-class, Subject-Dependent):** Phân loại đa lớp bằng cách kết hợp Valence và Arousal thành 4 góc phần tư cảm xúc (Q1, Q2, Q3, Q4). Mục tiêu là kiểm chứng độ ổn định của hệ thống trước bài toán phân loại phức tạp và đánh giá qua ma trận nhầm lẫn 4×4 .
3. **Exp 3 (Leave-One-Subject-Out - LOSO):** Thử thách thực tế nhằm kiểm chứng độ tổng quát hóa của mô hình trên cá thể hoàn toàn mới. Dữ liệu của 31 người được dùng để huấn luyện và kiểm thử chéo trên người dùng còn lại, quy trình này được lặp lại 32 lần.

3.2 Kiểm soát rò rỉ dữ liệu (Data Leakage)

Sự minh bạch trong thực nghiệm được đảm bảo qua các quy tắc:

- **Split trước, Normalize sau:** Thuật toán chuẩn hóa (StandardScaler) tuyệt đối không được tiếp xúc với toàn bộ tập dữ liệu. Việc fit bộ chuẩn hóa chỉ diễn ra trên tập Train, sau đó mới dùng tham số đó để transform tập Test.
- **Khởi tạo lại Scaler trong LOSO:** Ở kịch bản kiểm thử chéo cá nhân (Exp 3), bộ Scaler bắt buộc phải được khởi tạo mới trong mỗi vòng lặp fold, ngăn chặn việc mô hình lưu lại phân phối dữ liệu của người dùng trước đó.

3.3 Xử lý ngoại lệ và Tiêu chí đánh giá (Metrics)

Dữ liệu sinh lý thực tế chứa sự lệch nhãn cực kỳ nghiêm trọng ở một số cá thể (điển hình như Subject 23 đánh giá 100% video là Low Arousal, hay Subject 26 chỉ có 1 tín hiệu High Arousal).

- Cơ chế phòng thủ (Edge Case Handling) được thiết lập để bỏ qua những fold chứa dữ liệu của người dùng chỉ có 1 class nhằm tránh mô hình bị sụp đổ hoặc báo cáo kết quả ảo.
- Với tình trạng mất cân bằng cực bộ như trên, việc dùng độ chính xác (Accuracy) sẽ gây ra nghịch lý đánh giá (đoán toàn bộ là Low vẫn đạt độ chính xác cao). Do đó, **F1-Score (Macro)** được lựa chọn làm tiêu chuẩn đánh giá mang tính quyết định.

- Đồng thời, hàm tổn thất `nn.CrossEntropyLoss` trong các mạng Deep Learning được bổ sung trọng số lớp động (Dynamic Class Weights), tính toán lại theo từng fold nhằm ép mô hình chú ý hơn vào các nhãn thiểu số. Raw Logits được đưa thẳng vào hàm loss thay vì sử dụng lớp Softmax tại lớp đầu ra của mạng nơ-ron.

4. Kiến trúc các mô hình

4.1 Tổng quan kiến trúc hệ thống

Để giải quyết bài toán phân loại cảm xúc từ tín hiệu EEG, nhóm nghiên cứu triển khai và so sánh song song ba hướng tiếp cận học máy độc lập: **SVM** (Support Vector Machine) với kỹ thuật trích xuất đặc trưng thống kê, **CNN 2D** (Convolutional Neural Network) khai thác cấu trúc không gian–thời gian của biên độ sóng, và **BiLSTM** (Bidirectional Long Short-Term Memory) mô hình hóa các phụ thuộc tuần tự hai chiều. Toàn bộ ba mô hình sử dụng chung một đường ống tiền xử lý và cùng dữ liệu đầu vào `X_epochs.npy` có kích thước $(N \times 32 \times 128)$, đảm bảo tính công bằng trong so sánh.

4.2 Mô hình SVM

4.2.1 Chiến lược trích xuất đặc trưng

Do SVM không học trực tiếp từ chuỗi thời gian thô, mỗi epoch có kích thước (32×128) được ánh xạ thành một vector đặc trưng phẳng trước khi đưa vào bộ phân loại. Nhằm khai thác thông tin tần số đặc thù của sóng não, nhóm loại bỏ dải Delta (do liên quan đến giấc ngủ sâu) và trích xuất ba tập đặc trưng trên 4 dải tần mục tiêu (θ : 4–8 Hz, α : 8–13 Hz, β : 13–30 Hz, γ : 30–45 Hz), tạo thành vector đặc trưng 312 chiều cho mỗi epoch:

- **Mật độ phổ công suất (PSD)**: Sử dụng phương pháp Welch với `nperseg=64` (overlap 50% mặc định, tạo 3 segments) để ước lượng phổ công suất cho 32 kênh. Giá trị PSD theo dải tần được biến đổi logarit (`log`) nhằm nén dải giá trị rất rộng $O(10^{-6})$ – $O(1)$ về thang đo đồng nhất với Asymmetry và DE (vốn cũng ở log-scale), tạo ra $32 \times 4 = 128$ đặc trưng.
- **Entropy vi phân (DE – Differential Entropy)**: Được tính theo công thức $DE = \frac{1}{2} \ln(2\pi e \sigma^2)$, trong đó σ^2 là phương sai của tín hiệu sau khi lọc thông dải (bandpass filter) bằng bộ lọc Butterworth bậc 5 cho từng dải tần mục tiêu. Phương pháp này đo lường trực tiếp độ phức tạp và tính ngẫu nhiên của tín hiệu trong miền thời gian, tạo ra $32 \times 4 = 128$ đặc trưng.

- **Bất đối xứng bán cầu não (Asymmetry):** Dựa trên phát hiện y sinh học về sự lệch pha hoạt động giữa bán cầu trái và phải khi xử lý cảm xúc tích cực/tiêu cực, nhóm tính toán sự chênh lệch logarit công suất $\log(P_{\text{left}}) - \log(P_{\text{right}})$ giữa 14 cặp điện cực đối xứng, tạo ra $14 \times 4 = 56$ đặc trưng.

4.2.2 Kỹ thuật làm mượt LDS

Tín hiệu EEG có đặc tính thay đổi rất nhanh và chứa nhiều nhiễu động, trong khi trạng thái cảm xúc thường biến đổi chậm. Để khắc phục, nhóm áp dụng bộ lọc Linear Dynamical System (LDS) theo công thức đệ quy:

$$\mathbf{x}'_t = \alpha \cdot \mathbf{x}_t + (1 - \alpha) \cdot \mathbf{x}'_{t-1}, \quad \alpha = 0.3 \quad (1)$$

Bộ lọc được áp dụng **sau khi chia tập huấn luyện và kiểm tra** để ngăn chặn rò rỉ dữ liệu. Mỗi partition (train hoặc test) được smooth riêng biệt theo từng đoạn video 60 epoch. Đối với kịch bản LOSO (khi epochs không xếp liên tiếp), hệ thống sử dụng index tuyệt đối (`original_indices`) để nhóm chính xác các epoch thuộc cùng một video và sắp xếp lại theo đúng thứ tự thời gian trước khi áp dụng LDS.

4.2.3 Thiết kế bộ phân loại

Chuẩn hóa dữ liệu. Nhóm áp dụng chiến lược chuẩn hóa hai tầng nhằm đồng thời khử sai biệt cá nhân và đồng bộ thang đo cho bộ phân loại:

- **Tầng 1 – Chuẩn hóa riêng từng người (Per-subject Z-score):** Trong kịch bản LOSO (Subject-Independent), sau khi chia train/test, mỗi subject được chuẩn hóa Z-score riêng biệt bằng `StandardScaler`. Các scaler được fit trên dữ liệu huấn luyện; đối với subject test (chưa từng xuất hiện trong tập train), scaler được fit riêng trên chính dữ liệu test của subject đó — việc này chỉ nhằm triệt tiêu sai biệt sinh lý cá nhân (subject-level shift) chứ không gây rò rỉ nhãn. Đối với kịch bản Subject-Dependent (Exp 1, Exp 2), bước này được bỏ qua vì mỗi mô hình chỉ huấn luyện trên dữ liệu của một subject duy nhất.
- **Tầng 2 – Chuẩn hóa toàn cục trong Pipeline:** Một `StandardScaler` được đặt bên trong Pipeline huấn luyện, chỉ fit trên tập huấn luyện của mỗi fold, nhằm đồng bộ thang đo toàn bộ vector đặc trưng trước khi đưa vào SVM.

Bộ phân loại. Nhóm sử dụng máy hỗ trợ vector tuyến tính (`LinearSVC`) với hàm phạt L2 (`penalty='l2'`). Cơ chế chuẩn hóa L2 phân bổ đều trọng số cho tất cả các đặc trưng

thay vì triệt tiêu chúng về 0 như L1, giúp mô hình khai thác được cả những đặc trưng có mối tương quan yếu — điều quan trọng khi phân bố nhãn không đồng đều giữa các lớp.

Để đối phó với tình trạng mất cân bằng nhãn, tham số `class_weight='balanced'` được kích hoạt nhằm tự động điều chỉnh trọng số phạt tỷ lệ nghịch với tần suất xuất hiện của từng lớp.

Siêu tham số C được tối ưu hóa thông qua tìm kiếm lưới (Grid Search) kết hợp kiểm chéo phân tầng 5-fold (`StratifiedKfold`). Để tránh bias do cách chia dữ liệu cố định, seed của mỗi fold được thiết lập động theo công thức `seed = 42 + fold_index`.

Chiến lược chia dữ liệu.

- **Subject-Dependent** (Exp 1, Exp 2): Mỗi subject được huấn luyện riêng rẽ với `GroupKfold` ($k = 5$), chia theo video (mỗi video = 60 epoch) để tránh rò rỉ dữ liệu thời gian giữa các fold. Dữ liệu được truncate về bội số của 60 epoch trước khi chia để đồng bộ kích thước mảng.
- **Subject-Independent** (Exp 3): Sử dụng Leave-One-Subject-Out (LOSO), mỗi fold loại bỏ hoàn toàn 1 subject ra khỏi tập huấn luyện.

Phương pháp đánh giá. Kết quả được báo cáo bằng giá trị trung bình và độ lệch chuẩn trên tất cả các subject ($\text{Mean} \pm \text{Std}$) thay vì accuracy tổng gộp (pooled accuracy), nhằm tránh hiện tượng các subject “dễ dự đoán” kéo lệch kết quả chung.

Bảng 1: Siêu tham số mô hình SVM tuyến tính

Tham số	Giá trị	Mô tả
Thuật toán	<code>LinearSVC</code>	Máy hỗ trợ vector nhân tuyến tính, tối ưu cho dữ liệu chiều cao
Regularization	<code>L2 Penalty</code>	Hàm phạt L2 phân bổ đều trọng số, giúp khai thác các đặc trưng tương quan yếu
Tham số C	Tối ưu động	Tìm kiếm qua không gian mẫu $\{0.001, 0.01, 0.1, 1.0\}$
Class Weight Scaler	<code>balanced</code> 2 tầng	Trọng số động tỷ lệ nghịch với tần suất lớp Per-subject Z-score (LOSO) + Global <code>StandardScaler</code> trong pipeline
CV nội bộ LDS α	<code>StratifiedKfold</code> 0.3	5-fold phân tầng, seed động ($42 + \text{fold_index}$) Hệ số làm mượt, áp dụng SAU khi chia train/test
PSD	<code>Welch, nperseg=64</code>	3 segments averaging, log-transform
DE	Butterworth bậc 5	Bandpass filter + variance miền thời gian

4.3 Mô hình CNN 2D

4.3.1 Thiết kế kiến trúc

Mô hình CNN 2D xem mỗi epoch EEG như một ảnh 2D với kích thước $(1 \times 32 \times 128)$, trong đó trục dọc tương ứng với 32 kênh điện cực và trục ngang tương ứng với 128 timestep (1 giây @ 128 Hz). Dữ liệu đầu vào ban đầu có dạng $(N, 32, 128)$ và được thêm một chiều channel thông qua `unsqueeze(1)` trước khi đưa vào mô hình, tạo thành tensor $(N, 1, 32, 128)$ tương tự một ảnh xám đơn kênh.

Kiến trúc gồm bốn khối tích chập theo sơ đồ tăng dần độ sâu:

- **Block 1** ($1 \rightarrow 16$): Kernel (1×9) , quét temporal thuần túy, không trộn kênh EEG, theo sau bởi MaxPool (1×2) .
- **Block 2** ($16 \rightarrow 32$): Kernel (3×5) , bắt đầu học tương quan cross-channel, MaxPool (2×2) .
- **Block 3** ($32 \rightarrow 64$): Kernel (3×3) , MaxPool (2×2) .
- **Block 4** ($64 \rightarrow 128$): Kernel (3×3) , **không** có pooling để giữ biên trước GAP.

Mỗi ConvBlock tuân theo cấu trúc tuần tự `Conv2d` $\rightarrow$ `BatchNorm2d` $\rightarrow$ `ReLU` $\rightarrow$ `(MaxPool)`. Sau Block 4, **Global Average Pooling (GAP)** thay thế Flatten-FC lớn nhằm giảm mạnh số lượng tham số và hạn chế overfitting trên dữ liệu EEG có kích thước nhỏ.

Phân loại cuối được thực hiện qua một MLP nhỏ $128 \rightarrow 64 \rightarrow \text{num_classes}$, gồm hai lớp Dropout xen giữa: $p = 0.5$ ngay sau GAP (trước lớp Linear thứ nhất) và $p = 0.3$ giữa hai lớp Linear, giúp tăng khả năng tổng quát hóa của mô hình.

4.3.2 Khởi tạo trọng số

Kaiming Normal initialization được áp dụng cho tất cả các lớp `Conv2d` và `Linear` (phù hợp với hàm kích hoạt ReLU), trong khi `BatchNorm2d` sử dụng constant initialization với $\gamma = 1, \beta = 0$.

Bảng 2: Siêu tham số huấn luyện mô hình CNN 2D

Tham số	Giá trị	Mô tả
Batch size	256	Số mẫu mỗi bước cập nhật
Learning rate (LR)	3×10^{-4}	learning rate
Min LR	10^{-6}	Giới hạn dưới của LR (scheduler)
Max LR	10^{-2}	giới hạn trên của LR
Weight decay	10^{-4}	L2 regularization
Dropout	0.5 / 0.3	Sau GAP và giữa hai lớp FC
Patience (LR scheduler)	5	Số epoch chờ trước khi giảm LR
Max gradient norm	1.0	Gradient clipping
Max epochs	50	Giới hạn vòng lặp huấn luyện
Early stopping patience	15	số epoch quyết định dừng việc train

Lưu ý: các giá trị trên là cấu hình mặc định dùng cho Exp1 (valence binary) và Exp2 (4-class V×A) với StratifiedKFold 5-fold. Riêng Exp3 (LOSO – Leave-One-Subject-Out) sử dụng `early stopping patience = 20` để phù hợp với đặc điểm huấn luyện liên subject.

4.3.3 Cơ chế điều chỉnh Learning Rate thích nghi (AdaptiveLRScheduler)

Mô hình CNN 2D sử dụng bộ điều chỉnh learning rate tùy chỉnh `AdaptiveLRScheduler` dựa trên xu hướng F1-macro trên tập validation, được sử dụng ở file train hoạt động theo ba quy tắc với thứ tự ưu tiên cụ thể:

1. **Rule 2 – Boost LR thoát local minimum (ưu tiên cao nhất):** Nếu F1 tụt liên tục qua `drop_patience` (mặc định 3) epoch, LR được nhân với `boost_factor` (1.1), không vượt quá `max_lr` (10^{-2}). Bộ đếm được reset sau khi boost.
2. **Rule 1 – Giảm LR khi plateau:** Nếu Rule 2 không kích hoạt và F1 không cải thiện sau `patience` (mặc định 5) epoch liên tiếp, LR được nhân với `decay_factor` (0.5), không thấp hơn `min_lr` (10^{-6}). Bộ đếm được reset sau khi giảm.
3. **Rule 3 – Giữ nguyên LR:** Khi F1 cải thiện đủ lớn (vượt `best_f1 + min_delta`, với `min_delta = 10^{-4}`), cả hai bộ đếm được reset về 0 và LR được giữ nguyên.

Cơ chế này cho phép mô hình vừa giảm LR dần để hội tụ ổn định khi hiệu suất chững lại, vừa có khả năng "nhảy" ra khỏi local minimum khi hiệu suất liên tục suy giảm — một vấn đề thường gặp khi huấn luyện trên dữ liệu EEG có độ nhiễu cao.

4.4 Mô hình BiLSTM

4.4.1 Thiết kế kiến trúc

Mô hình mạng bộ nhớ ngắn hạn dài hai chiều (BiLSTM - Bidirectional Long Short-Term Memory) được thiết kế nhằm khai thác triệt để các phụ thuộc tuần tự hai chiều (bối cảnh quá khứ và tương lai) mã hóa trong chuỗi thời gian của tín hiệu EEG.

Dữ liệu đầu vào ban đầu có cấu trúc tensor dạng $(N, 32, 128)$ — tương ứng với N mẫu, 32 kênh điện cực và 128 timestep (tương đương với 1 giây dữ liệu ở tần số lấy mẫu 128 Hz). Trước khi đưa vào mạng, trục dữ liệu được hoán vị nội bộ (**permute**) để chuyển đổi thành cấu trúc $(N, 128, 32)$. Thao tác này biến đổi mỗi timestep trong chuỗi thành một vector 32 chiều, đại diện cho hoạt động điện thế đồng thời của toàn bộ các kênh tại một thời điểm cụ thể.

Kiến trúc mạng cốt lõi bao gồm hai lớp LSTM hai chiều xếp chồng lên nhau (Stacked BiLSTM) với cơ chế nén thông tin lũy tiến:

- **Lớp 1 (lstm1):** Nhận đầu vào chuỗi thời gian kích thước 32 chiều, cấu hình kích thước ẩn (**hidden_size**) bằng 64 và kích hoạt tính năng hai chiều (**bidirectional=True**). Đầu ra của toàn chuỗi có kích thước $(N, 128, 128)$, theo sau bởi một lớp điều hòa Dropout với xác suất tỷ lệ $p = 0.5$.
- **Lớp 2 (lstm2):** Nhận đầu vào là chuỗi đặc trưng 128 chiều từ lớp trước, cấu hình **hidden_size** bằng 32 và tiếp tục xử lý hai chiều. Đầu ra toàn chuỗi có kích thước $(N, 128, 64)$, theo sau bởi một lớp Dropout với hệ số $p = 0.5$.

Nhằm trích xuất tối ưu trạng thái hội tụ đặc trưng của cả hai chiều thời gian tại lớp thứ hai, nhóm nghiên cứu áp dụng **chiến lược trích xuất bất đối xứng** (Asymmetric Feature Extraction) thay vì chỉ sử dụng trạng thái cuối cùng của chuỗi phẳng. Cụ thể:

$$\mathbf{h}_{\text{forward}} = \mathbf{O}[:, -1, : 32], \quad \mathbf{h}_{\text{backward}} = \mathbf{O}[:, 0, 32 :] \quad (2)$$

Trong đó $\mathbf{O}$ là tensor đầu ra của lớp **lstm2**. Vector hướng xuôi ($\mathbf{h}_{\text{forward}}$) được thu thập tại timestep cuối cùng (vị trí -1), và vector hướng ngược ($\mathbf{h}_{\text{backward}}$) được thu thập tại timestep đầu tiên (vị trí 0). Hai thành phần này được liên kết tuyến tính (**torch.cat**) tạo thành một vector biểu diễn không gian ẩn tổng hợp gồm 64 chiều, trước khi truyền qua lớp tuyến tính (**Linear Classifier**) cuối cùng để thực hiện phân loại cảm xúc.

4.4.2 Thiết lập huấn luyện

Chi tiết cấu hình các siêu tham số áp dụng cho quá trình huấn luyện mô hình BiLSTM trong kịch bản độc lập người dùng (LOSO) được tổng hợp chi tiết tại Bảng 3.

Bảng 3: Siêu tham số huấn luyện mô hình BiLSTM (Thử nghiệm 3 — LOSO)

Tham số	Giá trị	Mô tả
Kích thước ẩn ($L1 / L2$)	64 / 32	Giảm dần dung lượng bộ nhớ ẩn để nén đặc trưng chuỗi
Tỷ lệ Dropout	0.5	Áp dụng sau mỗi lớp BiLSTM nhằm hạn chế quá khớp
Kích thước Batch	1024	Kích thước lô lớn, tối ưu hóa tính toán song song trên dual-GPU
Tốc độ học (LR)	3×10^{-4}	Sử dụng bộ tối ưu hóa Adam, <code>weight_decay</code> = 10^{-4}
Cắt xén Gradient	1.0	Kỹ thuật <code>clip_grad_norm</code> chống bùng nổ gradient
Độ chính xác hỗn hợp	AMP FP16	Tự động tăng tốc tính toán và tiết kiệm bộ nhớ GPU
Số Epoch tối đa	60	Giới hạn chu kỳ vòng lặp huấn luyện toàn cục
Patience (Early Stopping)	15	Dừng sớm dựa trên chỉ số F1-macro của subject kiểm thử

Tương tự như mô hình CNN 2D, tiến trình tối ưu hóa tốc độ học của BiLSTM được giám sát chặt chẽ bởi bộ điều chỉnh `AdaptiveLRScheduler` dựa trên biến động của chỉ số F1-macro tại tập kiểm thử của subject độc lập, tuân thủ nghiêm ngặt theo ba quy tắc phân tầng (*Boost / Decay / Hold*) đã được định nghĩa chi tiết tại Mục 4.3.3.

Sự mất cân bằng nhãn cục bộ giữa các phân đoạn hình ảnh/video được giải quyết triệt để thông qua hàm mất mát entropy chéo có trọng số động (`CrossEntropyLoss`). Trọng số của các lớp được tính toán độc lập cho mỗi fold LOSO bằng hàm `get_dynamic_class_weights` dựa trên phân phối nhãn thực tế của tập huấn luyện nền, với ngưỡng giới hạn trọng số phạt tối đa (`max_weight`) cố định bằng 5.0.

4.4.3 Chuẩn hóa dữ liệu

Trong kịch bản đánh giá Leave-One-Subject-Out (LOSO), dữ liệu EEG được áp dụng phương pháp chuẩn hóa theo từng kênh điện cực đơn lẻ (`mode='channel'`). Quy trình chuẩn hóa này bắt buộc phải thực hiện sau khi cấu trúc phân tách tập huấn luyện và tập kiểm thử hoàn tất. Việc fit các tham số thống kê (μ, σ) chỉ được thực thi trên phân phối của các subject thuộc tập train, ngăn chặn tuyệt đối hiện tượng rò rỉ thông tin phân phối (data leakage) từ đối tượng kiểm thử vào mô hình.

Khác biệt với mô hình học máy truyền thống SVM (vốn đòi hỏi quy trình chuẩn hóa hai tầng kết hợp chặt chẽ với per-subject Z-score để loại bỏ nhiễu biên độ), mô hình

BiLSTM chỉ yêu cầu một tầng chuẩn hóa per-channel duy nhất. Điều này khẳng định ưu thế vượt trội của các kiến trúc mạng hồi tiếp trong việc tự động học các đặc trưng biểu diễn nội tại dẻo dai (intrinsic representation learning) đối với cấu trúc tín hiệu chuỗi thời gian bất kể sự xê dịch biên độ sinh lý của từng cá nhân.

5. Kết quả thực nghiệm và So sánh mô hình

5.1 Kết quả Exp 1 — Phân loại nhị phân (Subject-Dependent, 5-Fold CV)

Bảng 4 tổng hợp kết quả trung bình qua 5 fold của ba mô hình trên bài toán phân loại Valence và Arousal.

Bảng 4: Kết quả Exp 1 — Phân loại 2 lớp (5-Fold Stratified CV)

Mô hình	Nhãn	Accuracy	Precision	Recall	F1-macro
SVM	Valence	0.5479 ± 0.0613	0.5130 ± 0.0540	0.5131 ± 0.0549	0.4989 ± 0.0541
	Arousal	0.5667 ± 0.0684	0.5287 ± 0.0612	0.5289 ± 0.0623	0.5173 ± 0.0620
CNN 2D	Valence	0.6700 ± 0.0033	0.6715 ± 0.0042	0.6700 ± 0.0033	0.6691 ± 0.0030
	Arousal	-	-	-	-
BiLSTM	Valence	0.6573 ± 0.0036	0.6580 ± 0.0040	0.6575 ± 0.0037	0.6571 ± 0.0034
	Arousal	0.6444 ± 0.0051	0.6461 ± 0.0043	0.6444 ± 0.0051	0.6433 ± 0.0057

5.2 Kết quả Exp 2 — Phân loại 4 lớp (Subject-Dependent, 5-Fold CV)

Bảng 5: Kết quả Exp 2 — Phân loại 4 lớp (5-Fold Stratified CV)

Mô hình	Accuracy	Precision	Recall	F1-macro
SVM	0.3597 ± 0.0815	0.2643 ± 0.0505	0.2652 ± 0.0505	0.2472 ± 0.0454
CNN 2D	0.4815 ± 0.0031	0.4773 ± 0.0030	0.4747 ± 0.0018	0.4701 ± 0.0024
BiLSTM	0.4672 ± 0.0059	0.4608 ± 0.0056	0.4614 ± 0.0054	0.4578 ± 0.0056

5.3 Kết quả Exp 3 — Leave-One-Subject-Out (LOSO)

Đây là kịch bản thực nghiệm khắt khe nhất, phản ánh khả năng tổng quát hóa thực sự của mô hình khi triển khai trên người dùng mới. Toàn bộ 32 subject được lần lượt trích ra làm tập test, phần còn lại dùng để huấn luyện.

Bảng 6: Kết quả Exp 3 — LOSO

Mô hình	Nhãn	Accuracy	Precision	Recall	F1-macro
SVM	Valence	0.5208 ± 0.0450	0.5206 ± 0.0443	0.5235 ± 0.0479	0.5106 ± 0.0437
	Arousal	0.5056 ± 0.0729	0.5053 ± 0.0709	0.5034 ± 0.0764	0.4935 ± 0.0772
CNN 2D	Valence	0.5973 ± 0.0979	0.5376 ± 0.0826	0.5401 ± 0.0407	0.5235 ± 0.0673
	Arousal	-	-	-	-
BiLSTM	Valence	0.5514 ± 0.0612	-	-	0.5020 ± 0.0367
	Arousal	0.5456 ± 0.0572	-	-	0.5025 ± 0.0292

5.4 Phân tích so sánh tổng thể

5.4.1 So sánh giữa các mô hình và cách thức huấn luyện mô hình

- SVM vs Deep Learning:** SVM là mô hình học máy truyền thống, hoạt động trên các đặc trưng thủ công (hand-crafted features) như Power Spectral Density (PSD) theo từng băng tần (theta, alpha, beta, gamma) được trích xuất trước khi đưa vào mô hình. Do đó, hiệu năng của SVM phụ thuộc rất lớn vào chất lượng và độ phù hợp của bước trích xuất đặc trưng — đây vừa là ưu điểm (mô hình nhỏ, huấn luyện nhanh, dễ diễn giải, ít tham số nên ít overfit trên dữ liệu nhỏ) vừa là hạn chế (không thể tự học các đặc trưng phức tạp, phi tuyến tính nằm ngoài tập đặc trưng đã định nghĩa trước). Ngược lại, CNN 2D và BiLSTM thuộc nhóm end-to-end deep learning, nhận trực tiếp tín hiệu EEG thô (sau chuẩn hóa) và tự học biểu diễn đặc trưng thông qua các lớp tích chập/hồi quy, cho phép khai thác các mẫu hình phức tạp mà đặc trưng thủ công khó nắm bắt. Đổi lại, các mô hình deep learning có số lượng tham số lớn hơn, đòi hỏi nhiều dữ liệu hơn và dễ overfit hơn trên tập DEAP có quy mô tương đối nhỏ (32 subjects), thể hiện qua việc cần áp dụng nhiều kỹ thuật regularization (Dropout, Weight Decay, Gradient Clipping, GAP thay Flatten-FC). Nhìn chung, SVM phù hợp khi cần một baseline nhanh, ổn định và ít tốn tài nguyên, trong khi CNN/BiLSTM hướng tới khai thác tối đa thông tin trong tín hiệu thô với chi phí tính toán và rủi ro overfitting cao hơn.
- CNN 2D vs BiLSTM:** Hai mô hình deep learning này khác biệt cơ bản ở **cách biểu diễn dữ liệu đầu vào và cơ chế học đặc trưng**. CNN 2D coi mỗi epoch EEG là một "ảnh" 2D ($1 \times 32 \times 128$), trong đó một trục là không gian (32 kênh điện cực) và trục còn lại là thời gian (128 timestep); các lớp tích chập với kernel không đối xứng (ví dụ (1×9) , (3×5)) cho phép mô hình học **tương quan không gian–thời gian cục bộ**, tức là các mẫu hình lặp lại trong một cửa sổ thời gian ngắn và sự liên kết giữa các kênh lân cận. Ngược lại, BiLSTM xử lý EEG như

một **chuỗi thời gian**, học sự phụ thuộc tuần tự (sequential dependency) theo cả hai chiều (quá khứ $\rightarrow$ tương lai và ngược lại) trên toàn bộ độ dài epoch, do đó có khả năng nắm bắt các xu hướng và động lực học (dynamics) dài hạn của tín hiệu mà CNN với receptive field giới hạn khó tiếp cận. Về cấu trúc, CNN 2D sử dụng các *ConvBlock* (Conv2D–BatchNorm–ReLU–Pool) xếp tầng để giảm dần kích thước không gian và tăng độ sâu đặc trưng, kết thúc bằng GAP; BiLSTM sử dụng các lớp LSTM hai chiều để mã hóa toàn bộ chuỗi thành một biểu diễn ẩn (hidden representation), sau đó đưa qua lớp phân loại. Nói cách khác, **CNN 2D mạnh về việc trích xuất các mẫu hình không gian–thời gian cục bộ và tương quan giữa các kênh**, còn **BiLSTM mạnh về việc mô hình hóa diễn biến và phụ thuộc thời gian dài của tín hiệu**. Trong thực nghiệm, sự khác biệt về hiệu năng giữa hai mô hình (Accuracy, F1-macro ở Exp1/Exp2) phản ánh việc đặc trưng nào — không gian–thời gian cục bộ hay phụ thuộc thời gian toàn cục — đóng vai trò quan trọng hơn đối với tín hiệu EEG cảm xúc của bộ dữ liệu DEAP.


- **Subject-Dependent vs LOSO:** Hai chiến lược đánh giá phản ánh hai bài toán hoàn toàn khác nhau. Với Subject-Dependent, mỗi subject được huấn luyện và đánh giá riêng rẽ bằng GroupKFold ($k=5$) chia theo video (mỗi video = 60 epoch), đảm bảo không có rò rỉ thời gian giữa các fold. Mô hình có cơ hội học được các đặc trưng *riêng biệt của từng cá nhân* (subject-specific patterns), do đó hiệu năng thường cao nhưng không phản ánh khả năng tổng quát hóa sang người dùng mới.

Ngược lại, LOSO huấn luyện trên $N - 1$ subjects và kiểm thử hoàn toàn trên subject còn lại — mô hình **chưa từng thấy bất kỳ dữ liệu nào** của subject test. Kết quả LOSO phản ánh đúng khả năng tổng quát hóa *cross-subject*, vốn là yêu cầu thực tế đối với ứng dụng EEG-BCI.

Trên thực nghiệm, hiệu năng ở chế độ LOSO của CNN 2D (Exp3) suy giảm đáng kể so với Subject-Dependent (Exp1) — mức chênh lệch Accuracy/F1-macro thường rơi vào khoảng [XX]–[XX] điểm phần trăm — phản ánh sự khác biệt sinh lý lớn giữa các cá nhân (inter-subject variability) trong tín hiệu EEG, khiến các đặc trưng học được từ nhóm subject huấn luyện không hoàn toàn chuyển dịch (transfer) sang subject mới. Mức suy giảm này cũng là động lực cho việc áp dụng các chiến lược cá nhân hóa như fine-tuning (xem `train_EEGNet_fine-tuning.py`), nhằm thu hẹp khoảng cách giữa hiệu năng Subject-Dependent (cận trên lý thuyết) và hiệu năng cross-subject thực tế (LOSO).

5.4.2 Phân tích hiện tượng Overfitting

Kết quả thực nghiệm cho thấy các mô hình học sâu làm việc trực tiếp với biên độ sóng thô có xu hướng overfitting đáng kể trong kịch bản LOSO. Điều này phù hợp với phân tích lý thuyết: tín hiệu EEG thô có SNR rất thấp và tính biến thiên cá thể cao, khiến mô hình học thuộc lòng các đặc trưng nhiễu thay vì học các pattern cảm xúc bất biến.



Hình 1:

6. Cải tiến mô hình

Xuất phát từ những hạn chế được nhận thấy trong quá trình huấn luyện mô hình, nhóm nghiên cứu đề xuất một chiến lược cải tiến toàn diện theo hai hướng bổ trợ cho nhau: (i) trích xuất đặc trưng miền tần số thay vì dùng biên độ thô, và (ii) xây dựng kiến trúc mô hình chuyên biệt cho EEG.

6.1 Cải tiến đường ống đặc trưng: PSD và Differential Entropy

Thay vì đưa trực tiếp biên độ sóng thô vào mô hình, nhóm trích xuất vector đặc trưng 312 chiều cho mỗi epoch trên bốn dải tần mục tiêu: θ (4–8 Hz), α (8–13 Hz), β (13–30 Hz), γ (30–45 Hz), bằng ba phương pháp:

- **Mật độ phổ công suất (PSD):** Sử dụng phương pháp Welch (nperseg=64, chồng lấn 50%) để ước lượng năng lượng tín hiệu. Giá trị PSD được lấy logarithm nhằm nén phân phối lệch phải và đồng bộ thang đo với DE và Asymmetry. Kết quả: $32 \times 4 = 128$ đặc trưng.
- **Entropy vi phân (DE):** Tín hiệu mỗi kênh được lọc thông dải bằng bộ lọc Butterworth bậc 5 cho từng dải tần, sau đó tính phương sai σ^2 trên miền thời

gian. DE được xác định theo:

$$DE = \frac{1}{2} \ln(2\pi e \cdot \sigma^2) \quad (3)$$

DE đã được chứng minh là đặc trưng hiệu quả hơn PSD trong nhận diện cảm xúc EEG [1]. Kết quả: $32 \times 4 = 128$ đặc trưng.

- **Bất đối xứng bán cầu não (Asymmetry):** Dựa trên phát hiện y sinh học về sự bất đối xứng hoạt động não khi xử lý cảm xúc, nhóm tính chênh lệch năng lượng logarit giữa 14 cặp điện cực đối xứng:

$$Asym(f) = \log P_{\text{left}}(f) - \log P_{\text{right}}(f) \quad (4)$$


Kết quả: $14 \times 4 = 56$ đặc trưng.

Tổng hợp ba nhóm đặc trưng ($128 + 128 + 56 = 312$ chiều) cung cấp cho bộ phân loại ba góc nhìn bổ trợ: năng lượng phổ (PSD), độ phức tạp phi tuyến (DE), và tương quan không gian liên bán cầu (Asymmetry).

Việc thay thế biên độ sóng thô bằng đặc trưng miền tần số kỳ vọng giải quyết trực tiếp vấn đề SNR thấp, vì các đặc trưng tần số phản ánh trạng thái dao động ổn định của não bộ thay vì các biến động ngẫu nhiên ngắn hạn.

6.2 Kiến trúc lai CNN-BiLSTM (Dual-Branch Fusion với DGCNN)

Để đồng thời khai thác cả đặc trưng không gian giữa các điện cực và đặc trưng chuỗi thời gian tần số, nhóm đề xuất kiến trúc lai **CNN-BiLSTM Dual-Branch Fusion** với hai luồng xử lý song song, hợp nhất tại lớp phân loại chung.



Hình 2: Kiến trúc CNN-BiLSTM Dual-Branch Fusion...

6.2.1 Chuẩn bị đặc trưng đầu vào

Thay vì đưa biên độ sóng thô vào mô hình, kiến trúc này sử dụng hai dạng đặc trưng được trích xuất đồng thời từ mỗi epoch (32×128) bởi `EEGFeatureExtractor`:

- **Chuỗi thời gian tần số (`X_freq_seq`):** Sử dụng cửa sổ trượt (window: 64 mẫu, stride: 16 mẫu) trên tín hiệu đã lọc dải tần. Tại mỗi cửa sổ, Entropy vi phân (DE) được tính trên 5 dải ($\delta, \theta, \alpha, \beta, \gamma$) cho 32 kênh. Kết quả là chuỗi có kích thước $(N, T_{seq}, 160)$ với $T_{seq} = (128 - 64)/16 + 1 = 5$ bước thời gian.
- **Đặc trưng đồ thị không gian (`X_graph`):** DE toàn epoch trên 5 dải tần, tạo thành ma trận nút $(N, 32, 5)$ — mỗi nút là một kênh điện cực với vector đặc trưng 5 chiều.

Bộ lọc Butterworth bậc 3 zero-phase (`filtfilt`) được dùng để tránh méo pha, và chuẩn hóa Z-score theo kênh (`mode='channel'`) được áp dụng **sau khi chia train/test** để ngăn rò rỉ dữ liệu.

6.2.2 Nhánh A — DGCNN (Dynamic Graph Convolutional Neural Network)

Nhánh A xử lý `X_graph` $(N, 32, 5)$, mô hình hóa mối tương quan không gian động giữa các điện cực. Điểm khác biệt so với CNN 2D truyền thống là ma trận kề **A** được học như một tham số của mô hình (không cố định trước), cho phép mô hình tự tìm ra cấu trúc tương quan điện cực phù hợp với nhiệm vụ phân loại cảm xúc:

$$\mathbf{A}_{norm} = \frac{\text{ReLU}(\mathbf{A} + \mathbf{A}^\top)/2}{\text{rowsum}(\cdot) + \epsilon} \quad (5)$$

Hai lớp tích chập đồ thị (`GraphConvolution`) được xếp chồng theo sơ đồ $5 \rightarrow 32 \rightarrow 32$, xen kẽ hàm kích hoạt ELU. Đầu ra được làm phẳng và chiếu qua MLP ($32 \times 32 \rightarrow 128 \rightarrow 64$) để thu được vector biểu diễn không gian 64 chiều.

6.2.3 Nhánh B — BiLSTM trên đặc trưng tần số

Nhánh B nhận `X_freq_seq` $(N, T_{seq}, 160)$ và đưa qua một lớp BiLSTM với `hidden_size = 64` (`bidirectional=True`). Vector biểu diễn thu được bằng cách nối trạng thái ẩn cuối của hai chiều, tạo thành vector 128 chiều. Tiếp theo, lớp tuyến tính FC chiếu về 128 chiều và áp dụng ELU để đồng bộ chiều với nhánh A trước khi hợp nhất.

6.2.4 Lớp hợp nhất và phân loại (Fusion Head)

Đầu ra của hai nhánh ($\mathbf{f}_A \in \mathbb{R}^{64}$ và $\mathbf{f}_B \in \mathbb{R}^{128}$) được nối tuyến tính:

$$\mathbf{f}_{fusion} = [\mathbf{f}_A || \mathbf{f}_B] \in \mathbb{R}^{192} \quad (6)$$

Vectơ hợp nhất được đưa qua hai đầu phân loại **độc lập** cho Valence và Arousal, mỗi đầu gồm `Linear(192 → 64) → ELU → Dropout(p=0.5) → Linear(64 → num_classes)`, cho phép mô hình học các đặc trưng riêng biệt cho từng chiều cảm xúc thay vì chia sẻ chung toàn bộ classifier.

6.2.5 Hàm mục tiêu tổng hợp (Joint Loss)

Mô hình được huấn luyện đồng thời trên cả hai nhãn bằng hàm tổn thất kết hợp:

$$\mathcal{L}_{total} = \mathcal{L}_{CE}^V + \mathcal{L}_{CE}^A + \lambda \cdot \mathcal{L}_{sup} \quad (7)$$

trong đó $\mathcal{L}_{CE}^V$ và $\mathcal{L}_{CE}^A$ là `CrossEntropyLoss` có trọng số động (`get_dynamic_class_weights`) cho Valence và Arousal; $\mathcal{L}_{sup}$ là hàm phạt tổng hợp tăng dần theo epoch nhằm giúp mô hình khai thác mối tương quan tiềm ẩn giữa hai nhãn cảm xúc (Supervision Loss). Hệ số λ được cố định bằng 1.0.

6.2.6 Chiến lược thích nghi cá nhân (Few-Shot Calibration)

Bên cạnh giao thức LOSO thuần túy (zero-shot), nhóm áp dụng thêm bước **few-shot calibration** nhằm cá nhân hóa mô hình với chi phí dữ liệu tối thiểu. Sau khi mô hình được huấn luyện LOSO trên 31 subject, một phần nhỏ dữ liệu của subject mục tiêu (20% — *calibration set*) được dùng để fine-tune có chọn lọc:

- **Đóng băng (Freeze):** Toàn bộ nhánh A (DGCNN) và nhánh B (BiLSTM) được đóng băng, giữ lại biểu diễn không gian và thời gian đã học từ tập huấn luyện.
- **Mở khóa (Unfreeze):** Chỉ lớp hợp nhất (Fusion Head) và ma trận kê động (**A**) trong DGCNN được cập nhật, cho phép mô hình điều chỉnh trọng số kết hợp đặc trưng theo đặc điểm sinh lý riêng của subject mục tiêu.

6.3 Mô hình EEGNet chuyên biệt

Nhận thấy rằng bộ dữ liệu DEAP chỉ bao gồm $32 \text{ đối tượng} \times 40 \text{ trial}$, tương ứng $N = 1280$ mẫu, một con số rất nhỏ so với các bài toán deep learning điển hình. Với chiến

lược K-Fold ($k = 5$), tập huấn luyện chỉ còn khoảng 1024 mẫu. Trong khi đó, mô hình EEGNet2D ban đầu có khoảng 50.000 tham số, dẫn đến tỉ lệ

$$\frac{N_{train}}{|\theta|} = \frac{1024}{50000} \approx 0.02,$$

, một tỉ lệ rất thấp dẫn tới nguy cơ overfitting nên ở đây nhóm chúng em giới thiệu tới mô hình EEGNet chuyên biệt nó sẽ làm giảm lượng tham số đi xuống chỉ còn vài nghìn tham số. Nhóm sử dụng phiên bản EEGNet được cải tiến với các thành phần sau:

- **Block 1 — Temporal Convolution:** Kernel (1×31) quét theo chiều thời gian mà không trộn kênh, theo sau bởi BatchNorm.
- **Depthwise Convolution:** Kernel ($C \times 1$) học bộ lọc không gian độc lập cho từng feature map, theo sau bởi BatchNorm, ELU và AvgPool.
- **SE Block (Squeeze-and-Excitation):** Cơ chế attention kênh giúp mô hình tập trung vào các đặc trưng quan trọng nhất, tích hợp sau mỗi pooling (một SE Block sau Block 1, một SE Block sau Block 2), trước khi đi qua Dropout.
- **Block 2 — Separable Convolution:** Tích chập tách biệt gồm Depthwise (1×15) học tương tác cross-channel, theo sau bởi Pointwise (1×1) để kết hợp thông tin giữa các feature map.
- **MaxNorm Constraint:** Giới hạn chuẩn trọng số ($\|\mathbf{w}\| \leq C_{\max}$) áp dụng sau mỗi bước cập nhật, với $C_{\max} = 1.0$ cho lớp Depthwise và $C_{\max} = 0.5$ cho lớp Linear cuối của Classifier.
- **Deep Classifier:** Flatten $\rightarrow$ Linear(64) $\rightarrow$ BatchNorm1d $\rightarrow$ ELU $\rightarrow$ Dropout $\rightarrow$ Linear($num_classes$).

Ngoài Dropout trong Classifier, mỗi Block (Block 1 và Block 2) còn có riêng một lớp Dropout ($p = 0.5$) áp dụng sau SE Block, giúp tăng khả năng tổng quát hóa ở nhiều mức biểu diễn khác nhau của mạng.

6.4 Fine-tuning thích nghi cá nhân (Subject-Specific Fine-tuning) dành cho EEGNet

Nhằm giải quyết vấn đề biến thiên cá thể lớn trong tín hiệu EEG, nhóm đề xuất kỹ thuật huấn luyện hai pha (Two-Phase Training) áp dụng cho EEGNet:

- **Phase 1 — Pre-training:** Mô hình được huấn luyện trên dữ liệu của $N - 1$ subject (31 người) theo giao thức LOSO để học các đặc trưng EEG chung, độc lập với cá thể. Để tăng khả năng tổng quát hóa, Phase 1 áp dụng thêm *Gaussian noise augmentation* ($\sigma = 0.01$) lên dữ liệu huấn luyện và *Label Smoothing* ($= 0.1$).
- **Phase 2 — Fine-tuning:** Trọng số từ Phase 1 được chuyển giao sang subject mục tiêu. Các lớp đầu (Temporal Conv, Depthwise) được đóng băng (*freeze*) để giữ lại kiến thức chung. Chỉ có các lớp cuối được fine-tune trên một phần nhỏ dữ liệu của subject mục tiêu (20% — *calibration set*). Label Smoothing ($= 0.1$) tiếp tục được áp dụng, nhưng không còn dùng noise augmentation.

Để tránh đóng băng vĩnh viễn các đặc trưng chung, tại một epoch xác định trong Phase 2 (*unfreeze_epoch*), Block 1 (Temporal Conv, Depthwise) được **mở lại (*unfreeze*)** và bổ sung vào optimizer với learning rate giảm $10\times$ so với learning rate của Phase 2. Cơ chế *dynamic unfreezing* này cho phép mô hình tinh chỉnh nhẹ cả phần đặc trưng tổng quát theo đặc điểm sinh lý riêng của từng subject, thay vì chỉ giới hạn việc học ở các lớp phân loại cuối.

Chiến lược này kỳ vọng khắc phục overfitting của LOSO thuần túy trong khi vẫn cá nhân hóa được mô hình theo đặc trưng sinh lý riêng của từng người, và bên cạnh đó — quan trọng nhất — có thể kéo hiệu năng của mô hình lên cao nhất có thể, qua đó ứng dụng được trong thực tế. Kết quả là khi train mô hình có F1-score đạt ngưỡng 0.5625 tốt hơn so với CNN2D khi train LOSO

6.5 Một số cải tiến khác

Bên cạnh các kiến trúc mô hình chính (CNN 2D, BiLSTM, EEGNet) và chiến lược huấn luyện hai pha, nhóm còn áp dụng một số kỹ thuật bổ trợ trong pipeline dữ liệu và huấn luyện nhằm tăng độ tin cậy và hiệu năng tổng thể của hệ thống:

- **Binarization nhãn theo Per-Subject Median:**
- **Chuẩn hóa dữ liệu sau khi chia Train/Test (tránh Data Leakage):**
- **Trọng số lớp động (Dynamic Class Weighting):**
- **Gradient Clipping:**
- **Trực quan hóa không gian đặc trưng bằng t-SNE:**

Các kỹ thuật trên, dù không phải là thành phần kiến trúc cốt lõi, đóng vai trò quan trọng trong việc đảm bảo tính **tin cậy của quy trình đánh giá** (tránh data leakage, tránh

lệch lớp) và **ổn định của quá trình huấn luyện** trên một bộ dữ liệu EEG có kích thước hạn chế và độ nhiễu cao như DEAP.

7. Hạn chế

Các kết quả thực nghiệm cho thấy tiềm năng của hướng tiếp cận đề xuất, song đồng thời cũng bộc lộ một số hạn chế vốn có của nghiên cứu.

- **Khoảng cách lớn giữa hiệu năng Subject-Dependent và LOSO:** Mức chênh lệch F1-macro giữa Exp 1 và Exp 3 lên đến hơn 14 điểm phần trăm ở CNN 2D (từ 0.669 xuống 0.524), phản ánh rào cản biến thiên cá thể chưa được giải quyết triệt để. Chiến lược few-shot calibration giúp thu hẹp khoảng cách này nhưng vẫn chưa đủ để đạt hiệu năng Subject-Dependent — cho thấy mô hình vẫn phụ thuộc đáng kể vào đặc trưng sinh lý riêng của từng cá nhân.
- **Hạn chế của chiến lược gán nhãn Global Median Thresholding:** Mặc dù cải thiện cân bằng nhãn so với ngưỡng cố định 5.0, ngưỡng trung vị toàn cục vẫn có thể không phản ánh đúng phân phối cảm xúc của từng cá nhân — một subject có thể đánh giá toàn bộ video trong khoảng điểm hẹp, khiến nhãn bị gán sai bản chất cảm xúc thực tế. Điều này đặc biệt rõ ở các subject bị bỏ qua trong thực nghiệm (Subject 23 chỉ có một nhãn Arousal duy nhất).
- **Quy mô dữ liệu nhỏ gây bất lợi cho Deep Learning:** DEAP chỉ có 32 subject $\times$ 40 trial, tương đương khoảng 1.280 epoch sau khi segment — quá nhỏ để các mô hình DL end-to-end học được biểu diễn có ý nghĩa từ biên độ sóng thô. Tỷ lệ $N_{train}/|\theta| \approx 0.02$ khiến CNN 2D và BiLSTM dễ rơi vào overfitting ngay cả khi áp dụng đầy đủ Dropout, BatchNorm và Gradient Clipping. SVM tránh được vấn đề này nhờ không gian đặc trưng 312 chiều đã được thiết kế bởi domain knowledge.
- **Các mô hình DL nhạy cảm với artifact của DEAP:** Tín hiệu EEG trong DEAP vẫn chứa artifact EMG và EOG dư sau preprocessing. Feature engineering của SVM lọc ngầm các artifact này thông qua bộ lọc Butterworth trước khi tính PSD và DE, trong khi CNN 2D và BiLSTM học trực tiếp từ biên độ đã chuẩn hóa — dẫn đến nguy cơ học thuộc các thành phần nhiễu thay vì các pattern cảm xúc thực sự.
- **Kết quả CNN-BiLSTM Fusion và EEGNet chưa được kiểm chứng đầy đủ:** Do giới hạn thời gian thực hiện, các mô hình giai đoạn hai (CNN-BiLSTM Dual-Branch Fusion, EEGNet với fine-tuning) chưa hoàn thiện đầy đủ kết quả thực

nghiệm so sánh. Phần đánh giá định lượng của các kiến trúc này sẽ được bổ sung trong phiên bản hoàn chỉnh.

8. Kết luận

Báo cáo này trình bày một hệ thống phân loại cảm xúc từ tín hiệu EEG trên bộ dữ liệu DEAP, được triển khai theo chiến lược hai giai đoạn có cấu trúc rõ ràng và quy trình đánh giá kiểm soát chặt chẽ.

Giai đoạn một thiết lập khung so sánh công bằng (*Fair Benchmark*) giữa ba mô hình đơn lẻ — SVM, CNN 2D và BiLSTM — trên cùng một data pipeline và cùng bộ metric. Kết quả cho thấy CNN 2D đạt F1-macro 0.669 ở kịch bản Subject-Dependent (Exp 1) và 0.524 ở LOSO (Exp 3); BiLSTM đạt lần lượt 0.657 và 0.502. Đáng chú ý, SVM với đặc trưng miền tần số thủ công (PSD, DE, Asymmetry) tuy có F1-macro thấp hơn ở Exp 1 (0.499) nhưng lại ổn định hơn trong kịch bản LOSO (0.511), cho thấy feature engineering giải quyết hiệu quả vấn đề SNR thấp và biến thiên cá thể mà DL end-to-end chưa vượt qua được trên tập dữ liệu nhỏ.

Quan sát này xác nhận giả thuyết cốt lõi của nhóm: các mô hình DL end-to-end không thất bại vì kiến trúc yếu, mà vì ba điều kiện tiên quyết chưa được đáp ứng — dữ liệu chưa đủ sạch, tập huấn luyện chưa đủ lớn, và chưa có cơ chế xử lý biến thiên cá thể. Đây chính là động lực dẫn đến giai đoạn hai.

Giai đoạn hai đề xuất hai hướng cải tiến bổ trợ: thay thế biên độ sóng thô bằng đặc trưng miền tần số (PSD, DE, Asymmetry) để giảm ảnh hưởng của artifact và SNR thấp; đồng thời xây dựng kiến trúc CNN-BiLSTM Dual-Branch Fusion kết hợp DGCNN học tương quan không gian điện cực động và BiLSTM nắm bắt diễn biến thời gian tần số. EEGNet chuyên biệt với Depthwise Convolution và SE Block giảm số tham số xuống còn vài nghìn, phù hợp với quy mô của DEAP, và được cá nhân hóa thêm thông qua chiến lược fine-tuning hai pha.

Hướng phát triển tiếp theo của nghiên cứu bao gồm áp dụng Euclidean Alignment toàn pipeline để chuẩn hóa phân phối tín hiệu giữa các subject trước khi huấn luyện, khai thác thêm topology điện cực chuẩn 10-20 vào cấu trúc đồ thị của DGCNN, và mở rộng thực nghiệm sang các bộ dữ liệu SEED và MAHNOB-HCI để đánh giá khả năng tổng quát hóa của kiến trúc đề xuất.

9. Phân chia công việc

Nguyễn Đức Long:

Tìm các bài báo chung liên quan đến chủ đề cho nhóm, làm mô hình CNN 2D và cải tiến bằng mô hình EEGNet chuyên biệt.

Phạm Thái Dương:

Tiền xử lí dữ liệu, làm mô hình BiLSTM và cải tiến kiến trúc lai CNN-BiLSTM.

Nguyễn Tiến Dũng:

Làm mô hình SVM, cải tiến các features cho mô hình SVM, tham gia vào quá trình hỗ trợ cải tiến cho 2 thành viên còn lại

Tài liệu

- [1] R.-N. Duan, J.-Y. Zhu, and B.-L. Lu, “Differential entropy feature for EEG-based emotion classification,” in *2013 6th International IEEE/EMBS Conference on Neural Engineering (NER)*, pp. 81–84, 2013.
- [2] S. Koelstra, C. Muhl, M. Soleymani, J.-S. Lee, A. Yazdani, T. Ebrahimi, T. Pun, A. Nijholt, and I. Patras, “DEAP: A database for emotion analysis using physiological signals,” *IEEE Transactions on Affective Computing*, vol. 3, no. 1, pp. 18–31, 2012.
- [3] J. A. Russell, “A circumplex model of affect,” *Journal of Personality and Social Psychology*, vol. 39, no. 6, pp. 1161–1178, 1980.
- [4] X.-W. Wang, D. Nie, and B.-L. Lu, “Emotional state classification from EEG data using machine learning approach,” *Neurocomputing*, vol. 129, pp. 94–106, 2014.
- [5] V. J. Lawhern, A. J. Solon, N. R. Waytowich, S. M. Gordon, C. P. Hung, and B. J. Lance, “EEGNet: a compact convolutional neural network for EEG-based brain–computer interfaces,” *Journal of Neural Engineering*, vol. 15, no. 5, p. 056013, 2018.